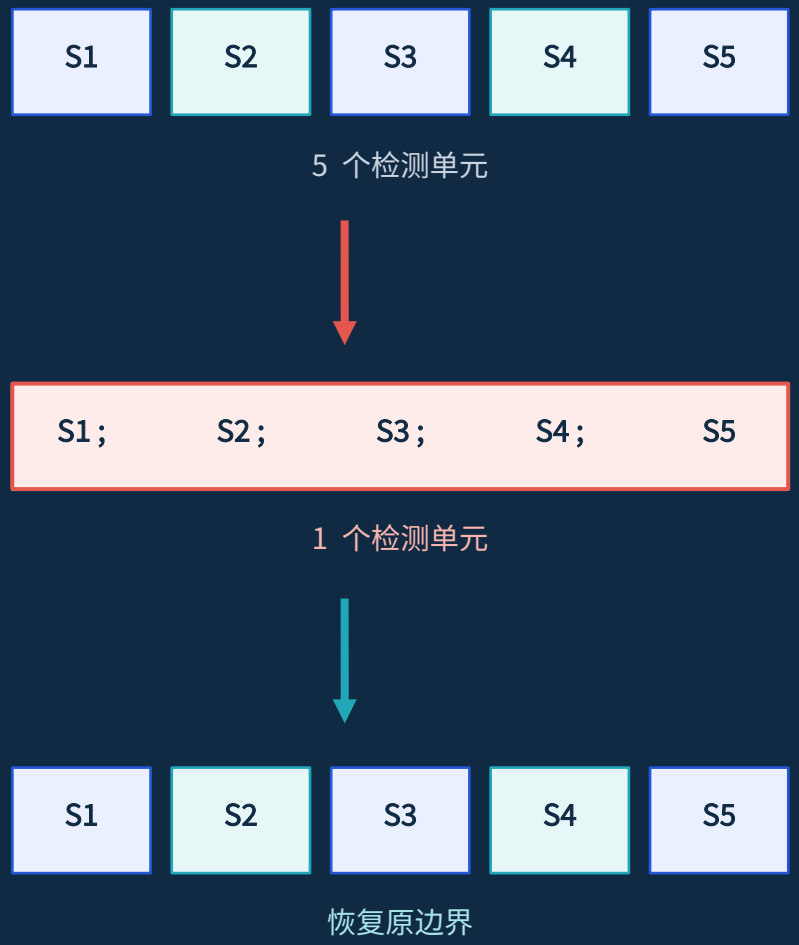
研究进展汇报

从复杂 AMR 攻击到句界诱因

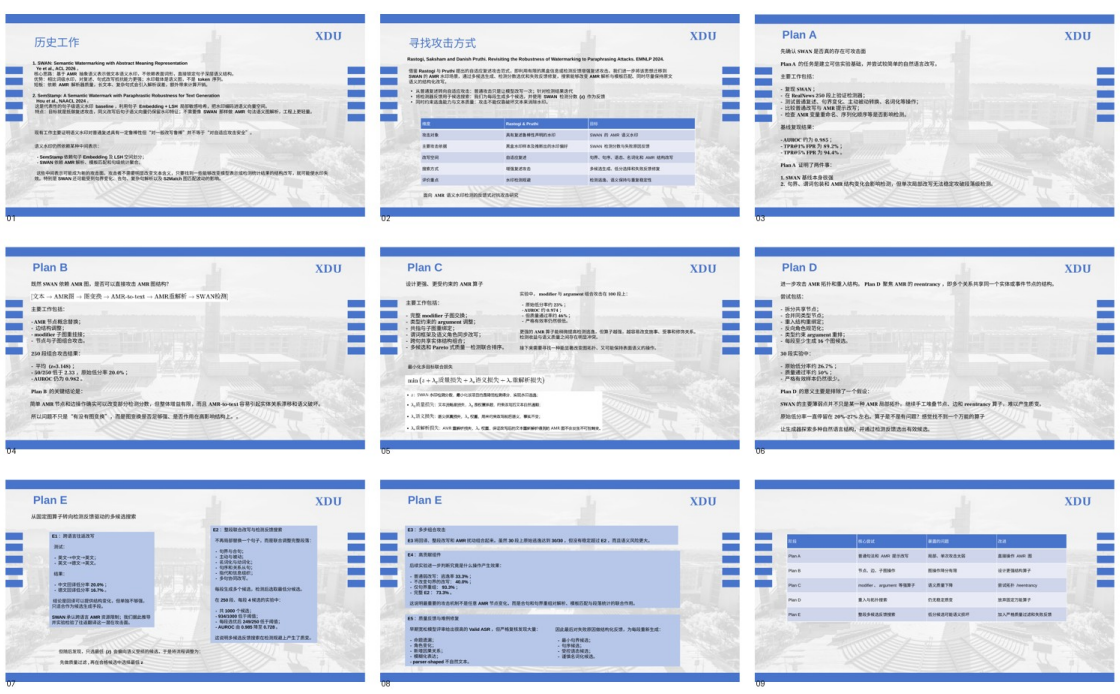
按“直觉 → 可证伪预测 → 对照实验”重构 SWAN 机制证据，并汇报后续认证防御的真实终态



quzehao • 2026.10.10

上次汇报只回答了“能否攻击”，没有回答“为什么”

Plan A--E 从简单改写一路走到多候选反馈搜索，但仍是方法堆叠



旧稿的结构：逐页解释 Plan A → B → C → D → E

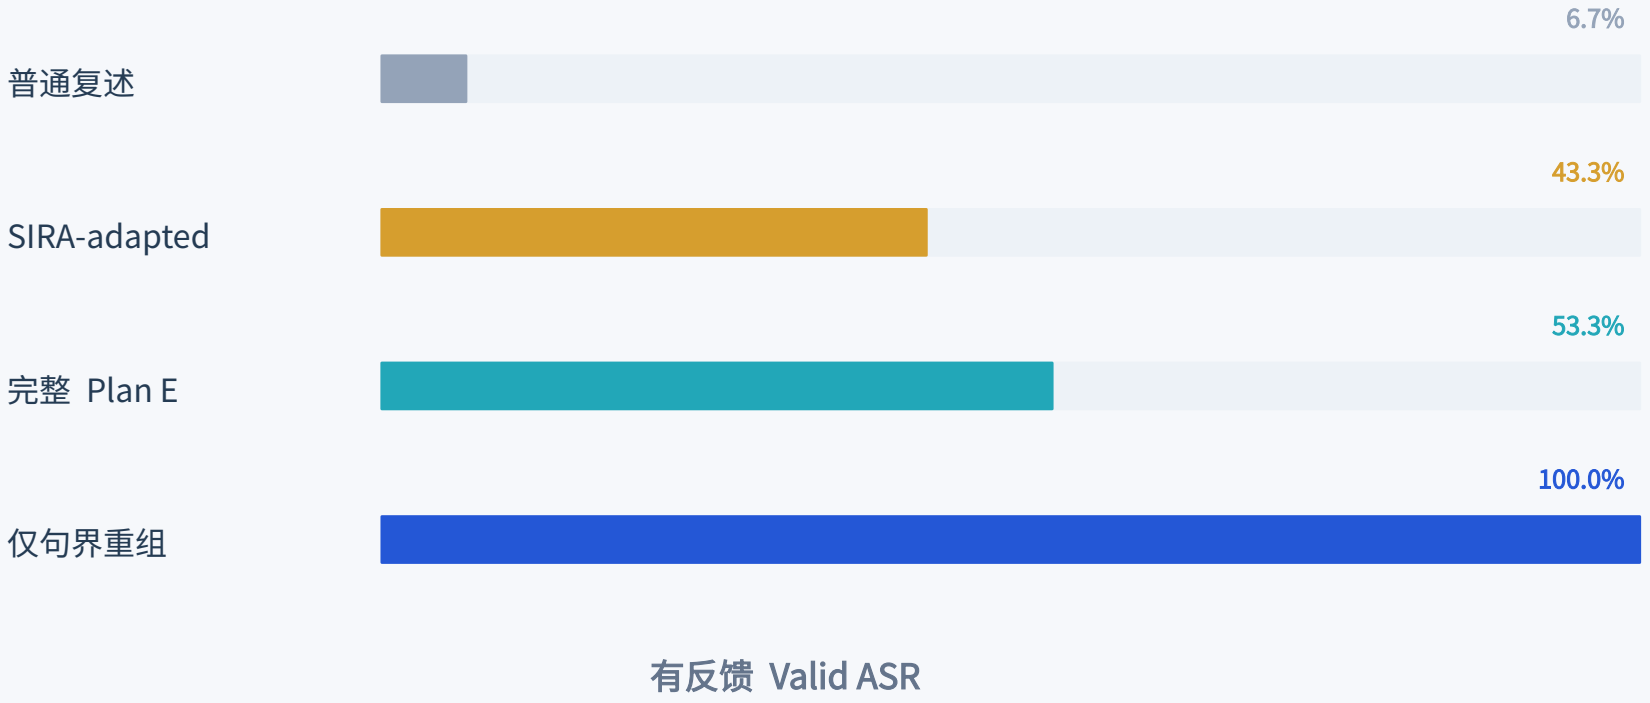
- A 普通改写 — 弱
- B AMR 图操作 — 20.0%
- C 强算子 — 质量下降
- D 重入拓扑 — 26.7%
- E 反馈搜索 — 低分显著

缺口：没有把“哪个变量触发了检测下降”单独拿出来验证

旧稿： ppt 演示 (1).pptx ； 历史结果保留，但不再按算子清单组织汇报。

同预算比较把句界重组筛成了主要诱因

30 个新 C4 提示、同模型、每段 K=4 、同质量门；句界臂在不读取检测分数时仍为 29/30



29/30

无反馈 Valid ASR

反馈选择只增加

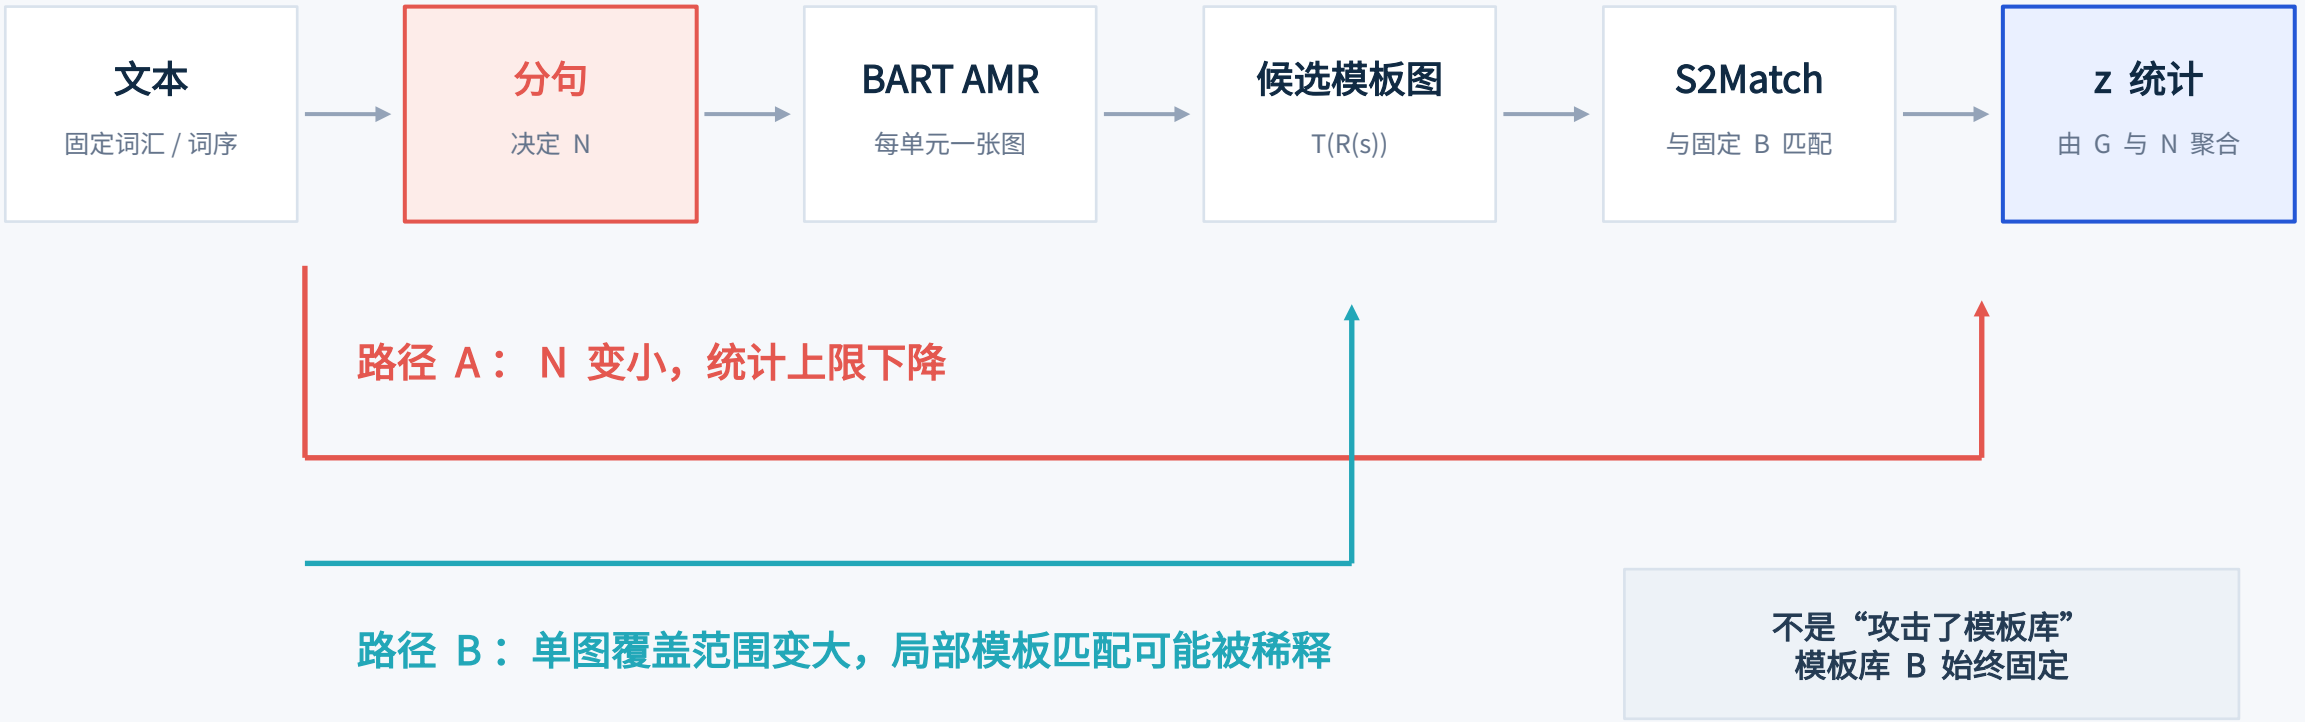
3.3 个百分点

直觉转向：效果主要来自操作本身，而不是“多试几个再挑最低分”

三臂主结果：普通复述 2/30 、完整 Plan E 16/30 、仅句界 30/30 ； SIRA-adapted 13/30 ，不是官方模型等价复现。

直觉：句界同时改变检测单元数和候选图作用域

SWAN 的模板库 B 固定不变；变化发生在输入如何被切分、解析、匹配和聚合



数据来源： CURRENT_RESULTS.md 、 CLAIM_EVIDENCE_MATRIX.md 、叙事 .md 、 semantic_watermark_defense PLAN v0.17 。

这一直觉导出四个可证伪预测

每个预测都对应一个独立实验；失败时应推翻或收窄直觉

P1

只改句末标点

固定词汇和词序时，判定仍应改变

P2

恢复 detector units

若是 unitization ，恢复五个单元应恢复判定

P3

只看统计量

N=1 时，即使全部命中也可能低于阈值

P4

固定 parser 输出

扩大候选图作用域也应降低模板匹配

下面四页按 P1 → P4 顺序报告证据

数据来源： CURRENT_RESULTS.md 、 CLAIM_EVIDENCE_MATRIX.md 、叙事 .md 、 semantic_watermark_defense PLAN v0.17 。

A--B--A 只改标点，并在检测端恢复原边界

同一批 30 个五句短文本；固定模板库、词汇和词序



词汇、词序、模板库 B 均保持不变

数据来源： CURRENT_RESULTS.md 、 CLAIM_EVIDENCE_MATRIX.md 、叙事 .md 、 semantic_watermark_defense PLAN v0.17 。

判定随句界可逆翻转



支持的有限结论：在这组 17--46 词短文本上， SWAN 的最终判定依赖外部句界。

不自动证明：所有标点版本语义严格等价； AMR 语义被攻击；正常长度同样成立。

统计路径：单检测单元的理论上限低于阈值

默认 λ=.25；预解析入口在 N=1 时仍计算 z

$$z = (G - \lambda N) / \sqrt{[N\lambda(1-\lambda)]}$$

当 N = 1 且唯一单元为 green

$$z_{max} = \sqrt{3} = 1.732$$

< 2.33 检测阈值

代数充分性拆分（30 个句界选择）

21/30 保持原命中率

只替换 N

30/30 保持原句数

只替换 green-rate

这两行允许非整数虚拟 G，只说明数值充分性，不是文本因果估计。

数据来源：CURRENT_RESULTS.md、CLAIM_EVIDENCE_MATRIX.md、叙事 .md、semantic_watermark_defense PLAN v0.17。

匹配路径：候选图扩大后局部模板分数被稀释

确定性图组合诊断固定了组成图与模板库，但人工组合图不是自然文本的 gold AMR



口径：该实验只说明 whole-graph S2Match 对候选图作用域敏感；不能据此排除真实攻击中的 parser drift 。

范围对照表明它不是通用水印移除方法

三种水印分别生成自己的水印文本；候选选择在读取目标检测分数前冻结



可以说

结果与 SWAN 的句级检测管线特异性相容

不能说

已经证明强系统特异性或其他水印普遍鲁棒

限制： SWAN 平均 30.9 词； KGW / SynthID 约 162.8 / 160.5 词，生成模型和长度未完全匹配。

数据来源： CURRENT_RESULTS.md 、 CLAIM_EVIDENCE_MATRIX.md 、叙事 .md 、 semantic_watermark_defense PLAN v0.17 。

防御探索没有闭环，正常长度因果端点也未补齐

所有路线按预注册门停止；没有把“接近通过”改写成正结果

局部多实例证据	开发集三种表示均未恢复	0/15	STOP
模板特异经验尾	原图 4/15；重解析 2/15	< 8/15 双门	STOP
关系锚定 motif	原图 41/56；重解析 33/56	各差 1 个	STOP
直接重新分句	有效逃逸 23/30 → 19/30	p = .125	线索
句数守恒构造	23/30 可合并； 0/30 可自然拆分	未运行 detector	STOP

因此当前只能主张“句界诱因已定位”，不能主张“已有有效分割不变防御”或“正常长度机制已确认”。

数据来源： CURRENT_RESULTS.md 、 CLAIM_EVIDENCE_MATRIX.md 、叙事 .md 、 semantic_watermark_defense PLAN v0.17 。

我把直觉进一步形式化为可认证重分句问题

这是独立的 SemStamp 防御证据流，不补 SWAN 的正常长度端点

SWAN 系统审计

whole-graph S2Match
难以分解 exact certificate

短文本 A--B--A 已成立
正常长度机制未完成

审计终态

Carrier--Decoder Contract

SemStamp certified defense

v1	fixed-byte renderer	42/3000 不可表达句界	STOP
v2	refined atoms	3000/3000 逐字节恢复	GO
v2	detector health	FPR 4.7% / TPR 95.4%	GO
v3	variable-N core	133,713,262-pair 验证	GO
v3	full profile	77.6152 > 72 GPU-h	STOP

最终没有生成 certificate： 失败的是资源 readiness ，不是授权不足，也不是已证明 SemStamp 不鲁棒。

数据来源： CURRENT_RESULTS.md 、 CLAIM_EVIDENCE_MATRIX.md 、叙事 .md 、 semantic_watermark_defense PLAN v0.17 。

当前结论：诱因已定位，完整防御证书仍未产生

把已支持、未支持和需要导师判断的内容分开

已支持

- 短文本 SWAN 判定对句界可逆敏感
- N 统计路径有确定代数解释
- whole-graph S2Match 对图作用域敏感

未支持

- 正常长度、句数守恒的因果端点
- 通用跨水印攻击或强系统特异性
- 有效 segmentation-invariant 防御

后续选择

- 论文主线收敛为 SWAN 系统审计
- 认证防御作为独立工程证据流
- 只有新版本资源方案过门才重启 certificate

希望老师确认：明天之后是否把论文叙事固定为“ SWAN 句界接口审计”，停止继续追逐一个尚未闭环的防御正结果？

数据来源： CURRENT_RESULTS.md 、 CLAIM_EVIDENCE_MATRIX.md 、叙事 .md 、 semantic_watermark_defense PLAN v0.17 。

附录：从 Plan A 到 Plan AE 的证据演进

不是 31 个并列实验，而是三次研究问题收敛



完整阶段叙事见： /Users/bytedance/AMR/ 叙事 .md 。

附录： SemStamp 健康门与 variable-N core 已通过

资源 Stop 之前， detector identity 、算法正确性和最大规模均已有独立证据

test FPR	positive TPR	systematic oracle
47/1000	954/1000	5000/5000
4.7%	95.4%	PASS

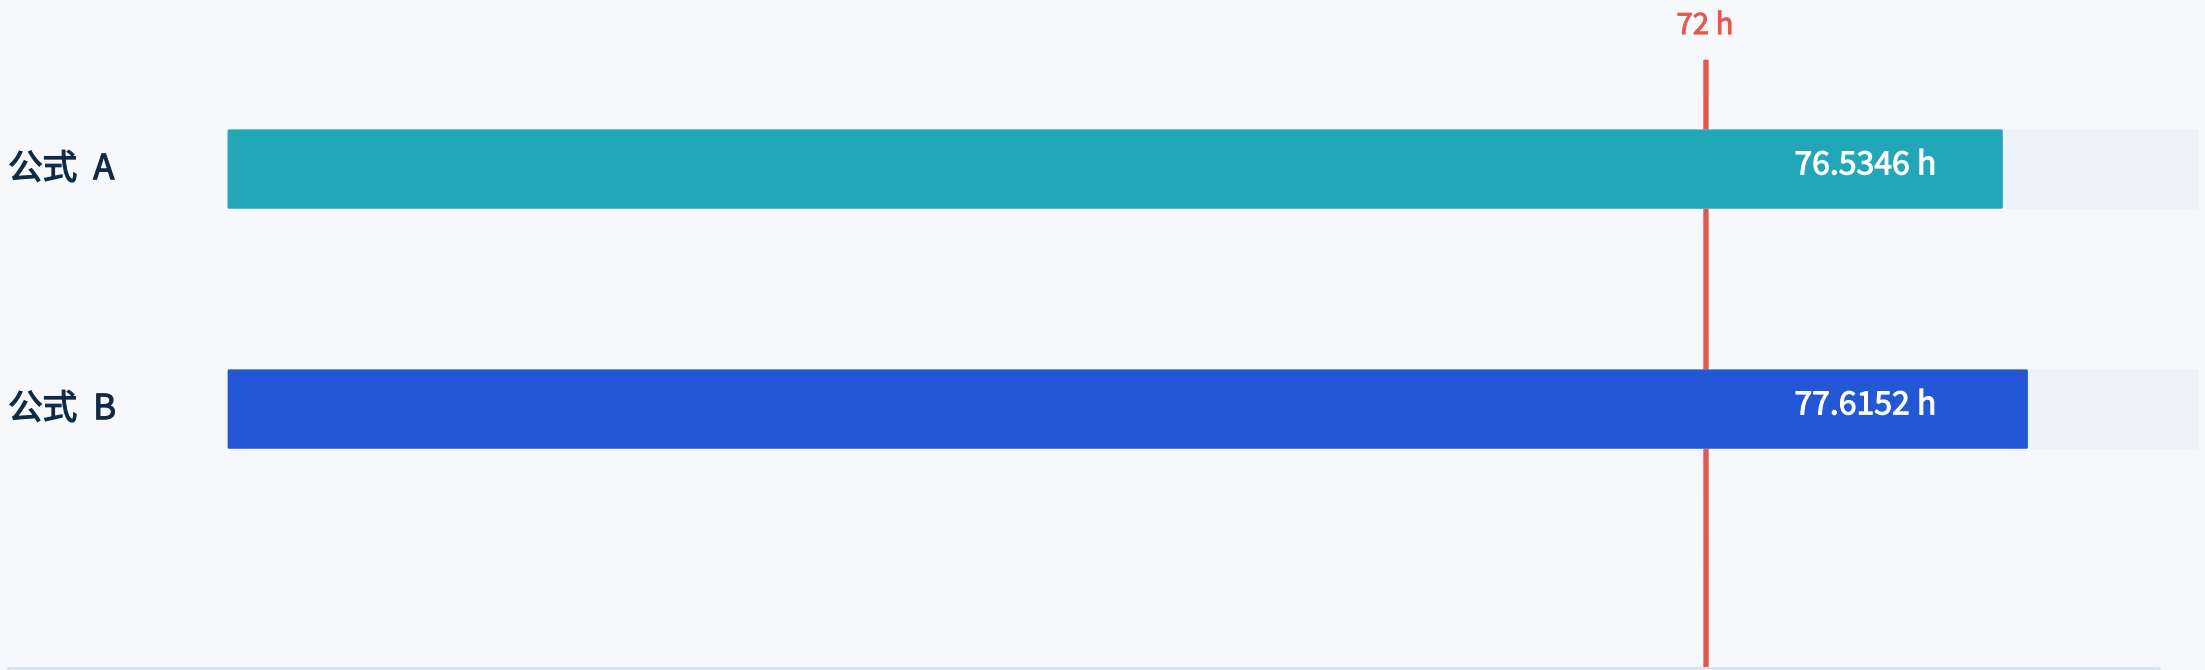
random oracle	fixed-N reduction	maximum scale
2000/2000	1000/1000	133,713,262
PASS	PASS	pairs

完整 profile 还保留了 3000/3000 行、 42/42 risk rows 、 59/59 zero-byte gaps 和全部 46,501 个 target layers 。

数据来源： CURRENT_RESULTS.md 、 CLAIM_EVIDENCE_MATRIX.md 、叙事 .md 、 semantic_watermark_defense PLAN v0.17 。

附录：最终停止项是 77.6152 GPU-hours 的资源门

两条冻结公式分别为 76.5346 和 77.6152 GPU-hours；取保守上界



主要预算来源	canonical batch-64 特征投影 128,650.4 秒 / replay	超过硬门 5.6152 h （7.80%）

batch 128 虽快 1.0333×，但会改变冻结 region array，因此不能用来跨过资源门。

数据来源： CURRENT_RESULTS.md 、 CLAIM_EVIDENCE_MATRIX.md 、叙事 .md 、 semantic_watermark_defense PLAN v0.17 。