语义水印的句界鲁棒性研究进展

从 SWAN 句界依赖审计到 SemStamp 可认证重分句防御



汇报人： quzehao · 2026.10.10

目录：从问题发现到当前终态

01 研究背景与核心问题

02 研究目标、创新思路与技术架构

03 实验方案、环境与人机职责

04 关键结果、异常与证据边界

05 下一阶段计划与总结

10 分钟讲法

问题 2 min
设计与架构 2 min
结果与异常 4 min
计划与总结 2 min

详细 Plan A--AE 时间线保留在 37 页版本中，本次主讲证据主线。

研究背景：早期找到了攻击面，但没有找到诱因



Plan A 基线

AUROC 0.985

Plan B--D 图算子

低分 20%--26.7%

Plan C 语义质量

仅 46% 通过

Plan E 反馈搜索

低分显著但混入质量失败

老师上次反馈对应的核心缺口：哪个变量真正触发检测下降?

研究目标与创新思路：从“找攻击”转向“验证句界”

我提出并冻结的诱因假设

句界同时改变

- **N**：检测单元数
- **Scope**：候选图作用域

→ 改变统计上限与模板匹配

- **P1**：只改标点仍改变判定
- **P2**：恢复 units 后判定恢复
- **P3**：N=1 的统计上限低于阈值
- **P4**：扩大图作用域降低局部匹配

扩展思路：对声明的全部合法 variable-N 重分句求 exact worst case 。

整体技术架构：我负责研究闭环， Agent 负责自动化执行

研究者设计

- 提出假设
- 定义 threat model
- 选择指标 / 对照
- 冻结 Go/Stop

→

Agent 执行

- 加载数据 / 模型
- 推理与 detector
- DP / C++ core
- 日志、 SHA 、指标

→

研究者裁决

- 复核异常
- 解释证据
- 决定 Stop/ 转向
- 限定论文主张

Agent 是可重复、可审计的实验执行工具，不是自主完成课题研究。

实验方案设计：四组证据逐层验证同一假设

实验组	数据与对照	核心指标	人负责	Agent
诱因筛选	30 个新 C4；三臂； K=4	Valid ASR	分组 / 质量门	推理统计
严格因果	同一 30 篇； A--B--A	配对翻转、 p	标点控制	检测重放
机制拆分	N 代数 + 固定图组合	z 、 F1 、 green	反事实口径	计算指标
范围对照	SIRA / KGW / SynthID	无反馈 ASR	基线选择	生成检测
认证预检	3×1000； radius 0--3	FPR/TPR 、 GPU-h	资源门	profile

实验逻辑和指标由我冻结；数据加载、模型推理、日志采集和指标计算由 Agent 执行。

实验环境与算力约束：先冻结资源门，再允许 Agent 执行

本地

协议 / CPU oracle / 审计

→

远端 RTX 3090

24GB · 隔离环境

→

Agent Supervisor

checkpoint / SHA / 重放

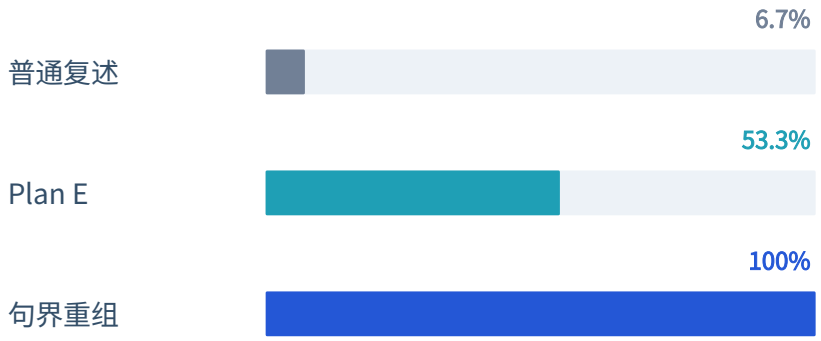
200M 单层 pairs	**2M** union spans	**16GiB** RSS
72h 双 replay	**2×** 确定重放	**0** 本轮模型训练

冻结对象：代码、模型、数据、 tokenizer 、 cohort identity ； 任一硬门失败即阻断后继任务。

实验结果：句界诱因得到确认，但认证证书未进入执行

以下结果由 Agent 流水线运行产生，并经人工复核

SWAN： 诱因与机制



A--B--A

1/30 → 30/30 → 1/30

p=3.73e-9 · zmax=1.732<2.33 · F1 0.8197→0.4502

SemStamp： 健康与资源

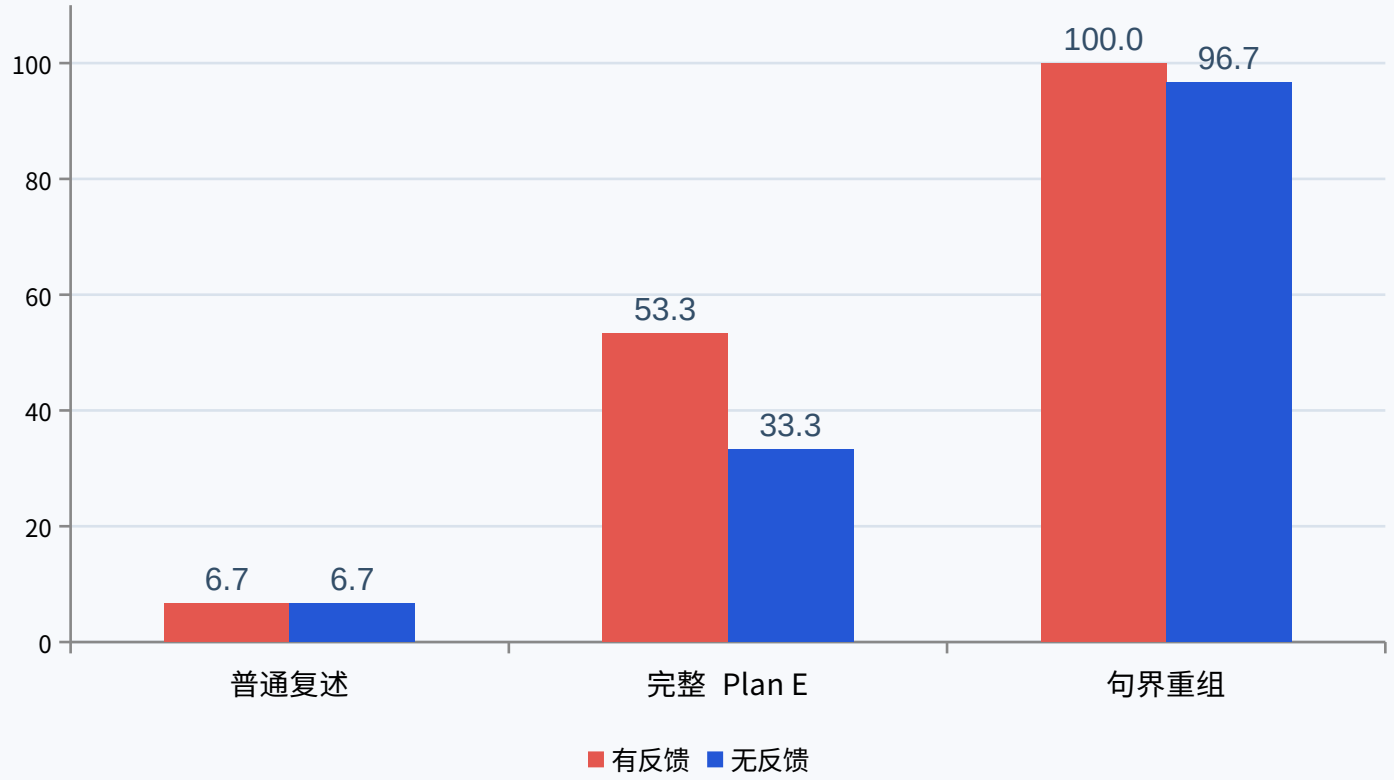
4.7% test FPR	95.4% positive TPR
46,501 target solves	77.6152h 保守双 replay

77.6152 > 72： certificate 保持未启动

结果由流水线计算；诱因解释、证据等级和 Stop 裁决由研究者负责。

阶段结果图①：句界优势不依赖检测反馈

Plan G：同一 30 篇、同模型、同 K=4 、同质量门



读图结论

29/30

句界无反馈 Valid ASR

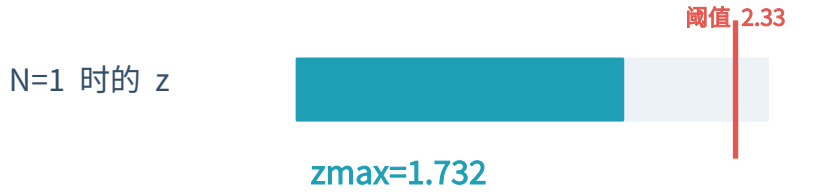
- 复杂 Plan E 在无反馈时降至 33.3%
- 句界无反馈仍为 96.7%
- 诱因来自操作本身，不依赖最低分筛选

该图完成“诱因筛选”，严格单变量因果仍由下一步 A--B--A 提供。

阶段结果图②：统计路径与匹配路径同时得到支持

两条证据强度不同：公式是确定解释，人工图是 scorer diagnostic

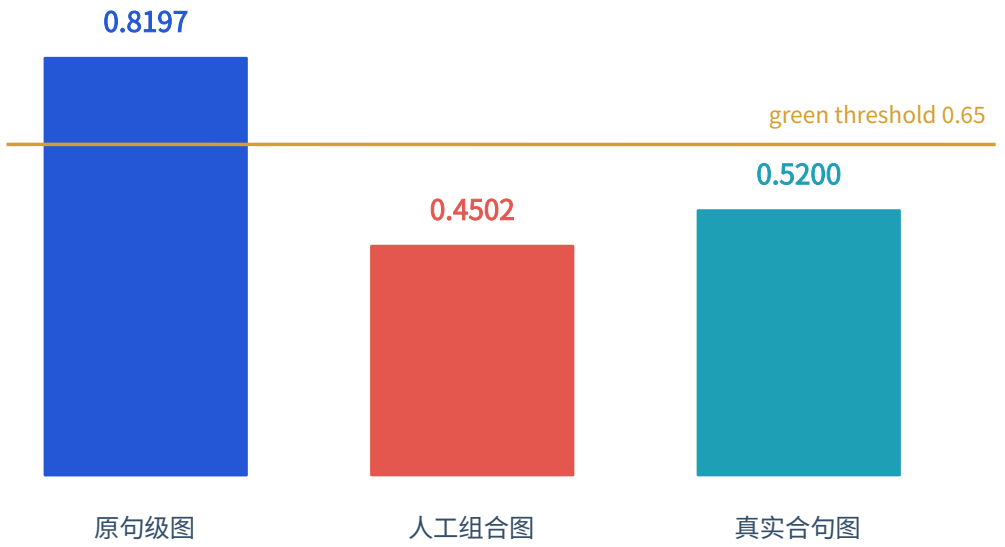
统计路径



21/30
只替换 N

30/30
只替换 green-rate

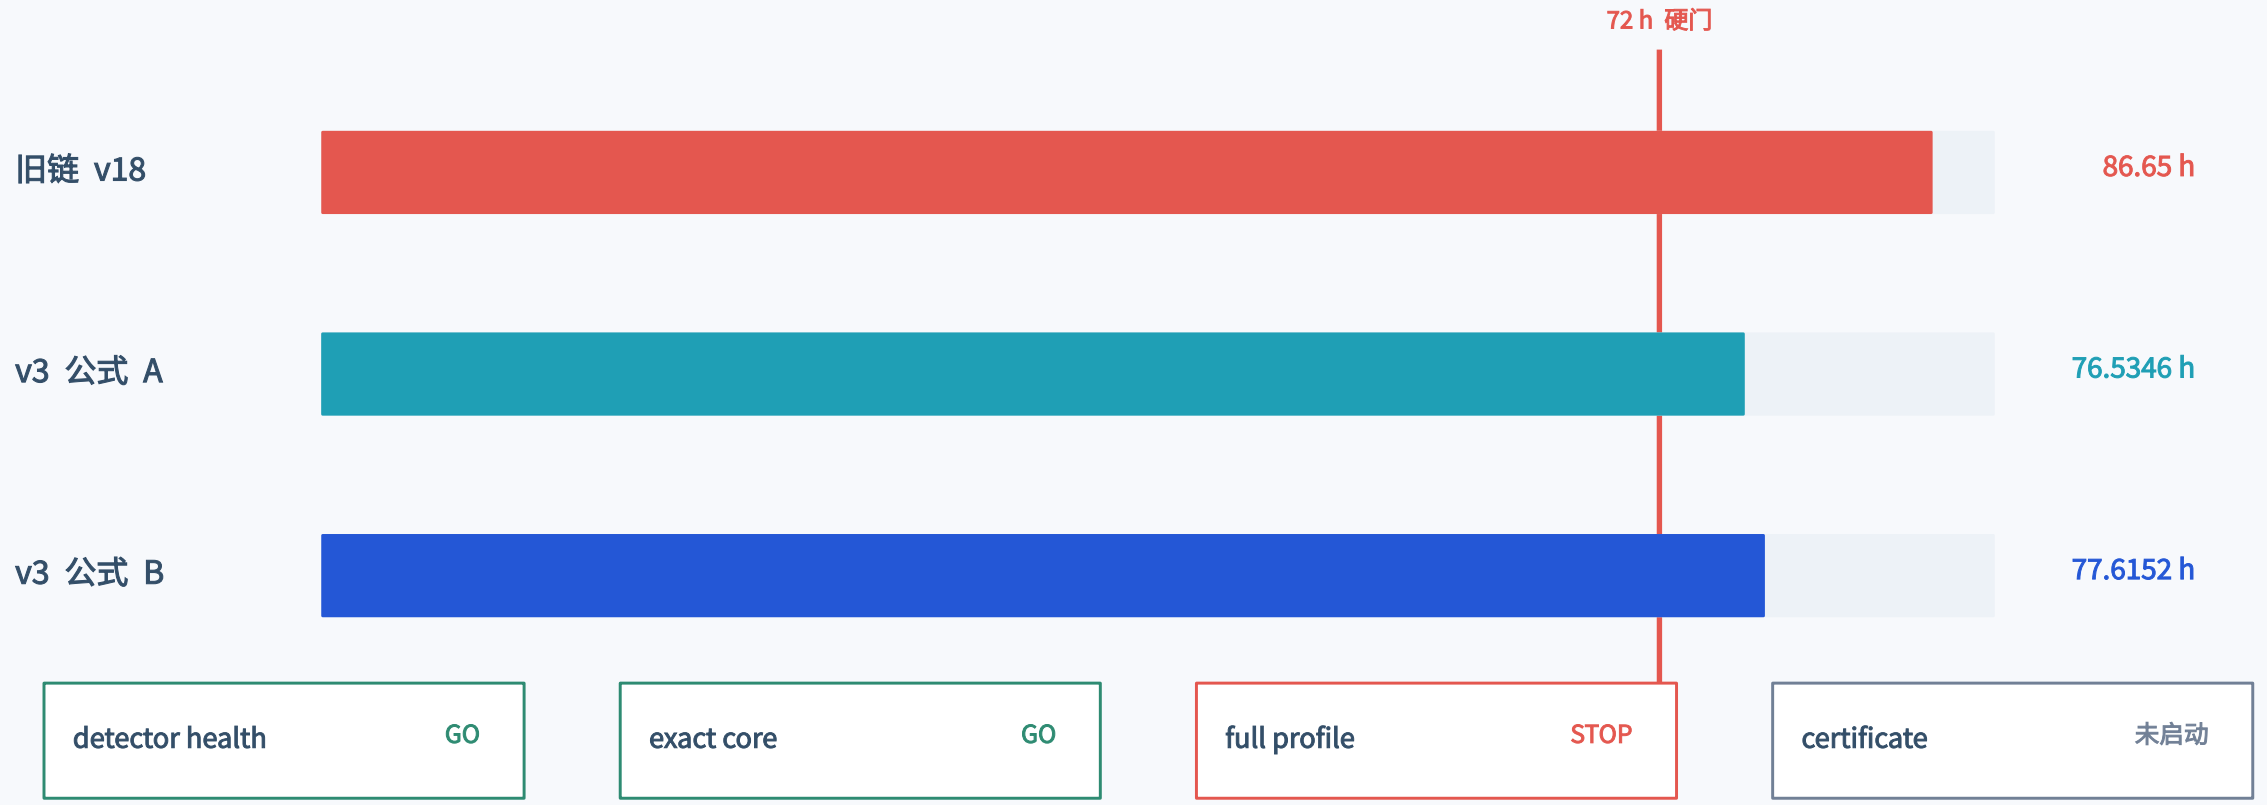
匹配路径： S2Match 中位 F1



统计路径解释 N 效应；图结果只证明作用域敏感，不能排除真实 parser drift 。

阶段结果图③：认证链最终停在资源门，而不是算法错误

三次 score-blind 预算均未进入正式 certificate



资源 Stop 只说明冻结实现与 RTX 3090 预算不足，不提供 SemStamp 鲁棒性结论。

当前问题与异常：数据、方法、实现和资源需要分开解释

外部有效性	核心 A--B--A 仅 30 篇，平均 30.9 词	
正常长度	23/30 可合并，但 0/30 有自然拆分点	
防御证据	局部证据、经验尾、 motif 均未过门	
renderer	v1 有 42/3000 句界落入 atom	
runner	v2 WP4 误用 fixed-N solver	
吞吐语义	batch128 改变冻结 region array	
资源	77.6152h ，超过硬门 5.6152h	

自动化不等于不会出错；价值在于异常可追踪、可封存、可按合同停止。

下一阶段计划：先做研究决策，再决定是否重启实验

近期必做

- 固定 SWAN 系统审计主线
- 完善 claim–evidence matrix
- 整理图表、局限与复现包

条件性重启

- 正常长度需新独立资产 + 真人质量门
- Certificate 需另立 v4
- 要求 batch64 等价且预算至少降低 7.8%

禁止操作

- 不删超限样本
- 不缩半径或 target layer
- 不事后提高资源门

我决定研究是否值得重启并冻结新协议； Agent 只在授权后执行。

总结：把“低分现象”收敛为可审计证据

诱因	句界改变 detector unitization
行为证据	固定词汇 / 词序， 1/30→30/30→1/30
机制支持	统计上限下降 + 图作用域匹配稀释
主张边界	短文本 SWAN 审计，不是通用攻击
防御终态	detector/core 已验证， certificate 未启动
人机边界	人负责研究设计； Agent 负责自动执行与留痕

最稳妥的论文定位： SWAN 句界接口审计；认证防御是独立且尚未产出 certificate 的证据流。

Q&A

建议讨论的三个研究决策

01 论文是否固定为 SWAN 句界接口审计?

02 正常长度端点是否值得重建独立人工质量资产?

03 SemStamp v4 是否值得为 7.8% 资源缺口继续投入?

备查材料

37 页完整时间线

逐页讲稿

所有 Go / Stop 与 SHA 链

谢谢